

# Лабораторная работа №4:

## Условная оптимизация

**Дисциплина:** Методы оптимизации

**Цель работы:** Изучение и практическое освоение методов условной оптимизации для решения задач нелинейного программирования с ограничениями.

### Теоретическая часть

#### Введение в условную оптимизацию

Задачи условной оптимизации возникают, когда необходимо найти минимум или максимум функции при наличии ограничений на ее переменные. Математическая постановка задачи в общем виде формулируется как:

$$\min_{x \in \mathbb{R}^n} f(x)$$

при условиях:

$$\begin{aligned} g_i(x) &\leq 0, & i = 1, \dots, m \\ h_j(x) &= 0, & j = 1, \dots, k \\ x_l &\leq x \leq x_u \end{aligned}$$

где  $f(x)$  - целевая функция,  $g_i(x)$  - функции ограничений-неравенств,  $h_j(x)$  - функции ограничений-равенств,  $x_l$  и  $x_u$  - нижние и верхние границы переменных.

#### Основные понятия

**Допустимое множество** - множество точек, удовлетворяющих всем ограничениям:

$$\Omega = \{x \in \mathbb{R}^n : g_i(x) \leq 0, h_j(x) = 0, x_l \leq x \leq x_u\}$$

**Активные ограничения** - ограничения, которые выполняются как равенства в точке минимума. Различают:

- Активные ограничения-неравенства:  $g_i(x^*) = 0$
- Активные ограничения-равенства:  $h_j(x^*) = 0$

**Локальный минимум** - точка  $x^* \in \Omega$  называется точкой локального минимума, если существует окрестность  $U$  этой точки такая, что  $f(x^*) \leq f(x)$  для всех  $x \in U \cap \Omega$ .

**Глобальный минимум** - точка  $x^* \in \Omega$  называется точкой глобального минимума, если  $f(x^*) \leq f(x)$  для всех  $x \in \Omega$ .

#### Условия оптимальности Куна-Таккера

Для задачи нелинейной оптимизации с ограничениями-неравенствами:

$$\min f(x) \quad \text{при условиях} \quad g_i(x) \leq 0, \quad i = 1, \dots, m$$

определим функцию Лагранжа:

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x)$$

где  $\lambda_i \geq 0$  - множители Лагранжа.

**Теорема Куна-Таккера** (необходимые условия оптимальности):

Если  $x^*$  - точка локального минимума и выполнены условия регулярности (например, условие линейной независимости градиентов активных ограничений), то существуют множители Лагранжа  $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)$  такие, что:

1. **Стационарность:**

$$\nabla_x L(x^*, \lambda^*) = \nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) = 0$$

2. **Допустимость:**

$$g_i(x^*) \leq 0, \quad i = 1, \dots, m$$

3. **Дополняющая нежесткость:**

$$\lambda_i^* g_i(x^*) = 0, \quad i = 1, \dots, m$$

4. **Неотрицательность:**

$$\lambda_i^* \geq 0, \quad i = 1, \dots, m$$

Для задач с ограничениями-равенствами и неравенствами условия дополняются соответствующими условиями для ограничений-равенств.

## Методы условной оптимизации

### 1. Метод доверительной области (trust-constr)

Алгоритм метода:

1. **Инициализация:**  $x_0, \Delta_0$

2. **Аппроксимация:** построение квадратичной модели целевой функции и линейной модели ограничений

3. **Решение подзадачи:**

$$\min_{p \in \mathbb{R}^n} m_k(p) = f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T B_k p$$

при условиях:  $g_i(x_k) + \nabla g_i(x_k)^T p \leq 0, \|p\| \leq \Delta_k$

4. **Обновление доверительной области** на основе соотношения фактического и предсказанного уменьшения:

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}$$

**Параметры радиуса доверительной области:**

- $\Delta_0$  - начальный радиус доверительной области
- $\Delta_{max}$  - максимальный радиус доверительной области
- $\Delta_{min}$  - минимальный радиус доверительной области
- $\eta_1, \eta_2$  - пороговые значения для принятия шага ( $0 < \eta_1 < \eta_2 < 1$ )
- $\gamma_1, \gamma_2$  - коэффициенты уменьшения/увеличения радиуса ( $0 < \gamma_1 < 1 < \gamma_2$ )

**Критерии сходимости:**

- $\epsilon_g$  - допуск на норму градиента:  $\|\nabla L(x^*, \lambda^*)\| \leq \epsilon_g$
- $\epsilon_c$  - допуск на выполнение ограничений:  $\|c(x^*)\| \leq \epsilon_c$
- $\epsilon_x$  - допуск на изменение переменных:  $\|x_{k+1} - x_k\| \leq \epsilon_x$

### Параметры подзадачи:

- $B_k$  - аппроксимация матрицы Гессе лагранжиана
- $\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}$  - показатель качества шага

В методе доверительной области  $p$  - это вектор шага, определяемый как решение подзадачи минимизации в пределах доверительной области:

$$p_k = \arg \min_{p \in \mathbb{R}^n} m_k(p)$$

где:

- $p \in \mathbb{R}^n$  - вектор шага из текущей точки  $x_k$
- $m_k(p)$  - локальная квадратичная модель целевой функции

### Свойства параметра $p$

#### 1. Ограничение нормы:

$$\|p\| \leq \Delta_k$$

где  $\Delta_k$  - текущий радиус доверительной области

#### 2. Структура квадратичной модели:

$$m_k(p) = f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T B_k p$$

#### 3. Условия оптимальности для $p$ :

Для найденного  $p_k$  должны выполняться условия Каруша-Куна-Таккера:

$$\begin{aligned} (B_k + \lambda I)p_k + \nabla f(x_k) + A_k^T \mu &= 0 \\ \mu_i(g_i(x_k) + \nabla g_i(x_k)^T p_k) &= 0 \\ \mu_i &\geq 0 \\ \|p_k\| &\leq \Delta_k \end{aligned}$$

### Вычислительные аспекты

#### Определение длины шага:

- Если  $\|p_k\| < \Delta_k$ , то ограничение неактивно
- Если  $\|p_k\| = \Delta_k$ , то шаг достигает границы доверительной области

#### Связь с фактическим шагом:

Новая точка вычисляется как:

$$x_{k+1} = x_k + p_k$$

#### Критерий принятия шага:

$$\rho_k = \frac{\text{actual reduction}}{\text{predicted reduction}} = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}$$

### Геометрическая интерпретация

- $p$  - направление и длина шага внутри доверительной области
- $p$  балансирует между направлением наискорейшего спуска и учетом кривизны функции
- При малых  $\Delta_k$ :  $p$  приближается к направлению наискорейшего спуска
- При больших  $\Delta_k$ :  $p$  приближается к шагу Ньютона

## Функция `scipy.optimize.minimize()`

### Ключевые параметры:

- `gtol` - допуск на градиент (обычно  $1e-8$ )
- `barrier_tol` - точность для барьерных методов
- `initial_tr_radius` - начальный радиус доверительной области
- `max_tr_radius` - максимальный радиус доверительной области
- `eta` - порог принятия шага ( $0 < \eta < 1$ )
- `initial_constr_penalty` - начальный коэффициент штрафа

### Специфические параметры:

- `factorization_method` - метод факторизации матриц
- `hess_update_strategy` - стратегия обновления гессиана
- `subproblem_algorithm` - алгоритм решения подзадачи
- `verbose` - уровень детализации вывода (0-3)

## 2. Последовательное квадратичное программирование (SLSQP)

На каждой итерации решается квадратичная подзадача:

$$\min_{d \in \mathbb{R}^n} \frac{1}{2} d^T H_k d + \nabla f(x_k)^T d$$

при условиях:

$$\nabla g_i(x_k)^T d + g_i(x_k) \leq 0$$

$$\nabla h_j(x_k)^T d + h_j(x_k) = 0$$

где  $H_k$  - аппроксимация матрицы Гессе лагранжиана.

### Параметры квадратичной подзадачи:

- $H_k$  - аппроксимация  $\nabla_{xx}^2 L(x_k, \lambda_k, \mu_k)$
- $\epsilon_H$  - параметр регуляризации гессиана
- $\tau$  - параметр для обеспечения положительной определенности

### Критерии остановки:

- Первый порядок оптимальности:
$$\left\| \begin{bmatrix} \nabla f(x) + A(x)^T \lambda \\ c(x) \end{bmatrix} \right\| \leq \epsilon_{opt}$$
- Допуск дополняющей нежесткости:  $\| \min(\lambda, -c(x)) \| \leq \epsilon_{comp}$

### Параметры обновления:

- $\alpha_k$  - длина шага, определяемая условием Вольфа или Армихо
- $\beta$  - параметр уменьшения шага ( $0 < \beta < 1$ )

# Параметр $\mathbf{d}$

## Математическое определение

В методе SLSQP  $\mathbf{d}$  - это вектор направления поиска, определяемый как решение квадратичной подзадачи программирования:

$$d_k = \arg \min_{d \in \mathbb{R}^n} q_k(d)$$

где квадратичная подзадача имеет вид:

$$\begin{aligned} \min_{d \in \mathbb{R}^n} & \frac{1}{2} d^T H_k d + \nabla f(x_k)^T d \\ & \nabla g_i(x_k)^T d + g_i(x_k) \leq 0 \quad (\text{неравенства}) \\ & \nabla h_j(x_k)^T d + h_j(x_k) = 0 \quad (\text{равенства}) \end{aligned}$$

## Свойства параметра $\mathbf{d}$

### 1. Локальная аппроксимация:

- $\mathbf{d}$  представляет направление, которое минимизирует квадратичную аппроксимацию целевой функции
- Одновременно удовлетворяет линейным аппроксимациям ограничений

### 2. Условия оптимальности:

Для оптимального  $d_k$  выполняются условия ККТ:

$$\begin{aligned} H_k d_k + \nabla f(x_k) + \sum \lambda_i \nabla g_i(x_k) + \sum \mu_j \nabla h_j(x_k) &= 0 \\ \lambda_i (\nabla g_i(x_k)^T d_k + g_i(x_k)) &= 0 \\ \lambda_i &\geq 0 \\ \nabla h_j(x_k)^T d_k + h_j(x_k) &= 0 \end{aligned}$$

## Структура и компоненты

### Составляющие направления:

- **Тангентальная компонента** - движение вдоль допустимого множества
- **Нормальная компонента** - движение toward допустимого множества

### Связь с полным шагом:

Фактическое обновление переменных:

$$x_{k+1} = x_k + \alpha_k d_k$$

где  $\alpha_k$  - длина шага, определяемая линейным поиском.

## Вычислительные аспекты

### Определение допустимости:

- Если  $d_k = 0$  и условия ККТ выполнены, достигнута стационарная точка
- Направление  $\mathbf{d}$  обеспечивает одновременное улучшение целевой функции и соблюдение ограничений

### Свойства матрицы Гессе:

- $H_k$  - положительно определенная аппроксимация гессиана лагранжиана
- Обеспечивает выпуклость квадратичной подзадачи

## Геометрическая интерпретация

- $\mathbf{d}$  - направление, которое ведет к допустимой точке с улучшенным значением функции
- В окрестности решения  $\mathbf{d}$  стремится к нулю
- Направление учитывает как градиент целевой функции, так и активные ограничения

## Функция `scipy.optimize.minimize()`

### Основные параметры:

- `ftol` - допуск по изменению функции (обычно 1e-6)
- `eps` - размер шага для численного дифференцирования
- `maxiter` - максимальное число итераций
- `disp` - флаг вывода результатов (0/1)

### Параметры точности:

- `tol` - общая точность решения
- `iprint` - уровень вывода итерационной информации
- `finite_diff_rel_step` - относительный шаг для конечных разностей

## 3. Метод штрафных функций

Преобразование задачи условной оптимизации в безусловную:

$$P(x) = f(x) + \mu \left[ \sum_{i=1}^m \max(0, g_i(x))^2 + \sum_{j=1}^k h_j(x)^2 \right]$$

### Параметры штрафной функции:

- $\mu$  - коэффициент штрафа в функции:  
 $P(x, \mu) = f(x) + \mu \cdot \Phi(x)$
- $\Phi(x) = \sum_{i=1}^m [\max(0, g_i(x))]^p + \sum_{j=1}^l |h_j(x)|^p$

### Стратегия увеличения штрафа:

- $\mu_{k+1} = \gamma \cdot \mu_k$ , где  $\gamma > 1$
- Критерий увеличения:  $\|\nabla \Phi(x_k)\| > \epsilon_\mu$

### Параметры точности:

- $\epsilon_\mu$  - точность для штрафного параметра
- $\epsilon_P$  - допуск для штрафной функции:  $\|\nabla P(x, \mu)\| \leq \epsilon_P$

## Функция `scipy.optimize.minimize()`

### Параметры штрафов:

- `mu` - коэффициент штрафа (начальное значение)
- `mu_update` - стратегия обновления коэффициента штрафа
- `penalty_type` - тип штрафной функции (квадратичная, точная и т.д.)

#### Параметры сходимости:

- `penalty_tol` - точность для штрафной функции
- `max_penalty_iter` - максимальное число итераций с увеличением штрафа
- `initial_penalty_param` - начальный параметр штрафа

## 4. Общие параметры для всех методов

#### Критерии остановки:

- `tol` - общий допуск сходимости
- `maxiter` - максимальное число итераций
- `disp` - вывод информации о процессе

#### Параметры производных:

- `jac` - метод вычисления якобиана {'2-point', '3-point', 'cs'}
- `hess` - метод вычисления гессиана
- `finite_diff_rel_step` - относительный шаг для конечных разностей

#### Дополнительно:

- `callback` - функция обратного вызова
- `options` - дополнительные специфические параметры

## Практическая часть

---

### Задача 1: Минимизация функции Розенброка с ограничениями

**Постановка задачи:** Найти минимум функции Розенброка от двух переменных при наличии ограничений.

#### Функция Розенброка:

$$f(x) = \sum_{i=1}^{n-1} [100(x_{i+1} - x_i^2)^2 + (1 - x_i)^2]$$

#### Ограничения:

- $0 \leq x_0 \leq 1$
- $-0.5 \leq x_1 \leq 2.0$
- $x_0 + 2x_1 \leq 1$
- $2x_0 + x_1 = 1$
- $x_0^2 + x_1 \leq 1$
- $x_0^2 - x_1 \leq 1$

# Используемые методы

## Метод доверительной области (trust-constr)

### Теория метода:

Метод trust-constr основан на последовательном решении приближенных задач в доверительной области. На каждой итерации:

1. **Построение модельной задачи:** Целевая функция аппроксимируется квадратичной формой, а ограничения - линейными функциями:

$$m_k(p) = f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T B_k p$$

где  $B_k$  - аппроксимация матрицы Гессе.

2. **Решение подзадачи:** Находится шаг  $p_k$ , минимизирующий  $m_k(p)$  при условиях:

$$g_i(x_k) + \nabla g_i(x_k)^T p \leq 0$$

$$\|p\| \leq \Delta_k$$

3. **Обновление доверительной области:** Вычисляется отношение фактического уменьшения к предсказанному:

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}$$

На основе  $\rho_k$  корректируется размер доверительной области  $\Delta_k$ .

### Преимущества для данной задачи:

- Эффективно работает с нелинейными ограничениями
- Использует информацию о вторых производных (матрица Гессе)
- Устойчив к плохой обусловленности

## Особенности реализации

### Градиент и матрица Гессе функции Розенброка:

$$\nabla f(x) = \begin{bmatrix} -400x_0(x_1 - x_0^2) - 2(1 - x_0) \\ 200(x_1 - x_0^2) \end{bmatrix}$$

$$\nabla^2 f(x) = \begin{bmatrix} 1200x_0^2 - 400x_1 + 2 & -400x_0 \\ -400x_0 & 200 \end{bmatrix}$$